

Data Fest 2026

SPEAKER DECK

Изучаем ML в опенсорс-проекте

история опенсорс-курса по ML для всех

Антон Костин · преподаватель в МФТИ · ML & Education

О СПИКЕРЕ

Антон Костин

Преподаватель в Московском физико-техническом институте

Люблю преподавать и работать в опенсорс-проектах ([CayleyPy](#), [Lawful Good Project](#)). По мере сил пытаюсь развивать проекты на пересечении ML, учебных курсов и опенсорса. В 2026 году разработал и запустил на Физтехе курс “Анализ данных в научной литературе”, который стал опенсорс-проектом. О нём я хочу сегодня рассказать.



ОПЫТ	10+ лет в высшей школе · 5+ лет в ML / NLP
СТЕК	PyTorch · HuggingFace · Git
КОНТАКТ	@visualcomments · aa.kostin@phystech.edu

S01

ОСНОВНАЯ ИДЕЯ КУРСА

ML через вклад

Учимся, строя настоящий инструмент

код

данные

граф

модель

личный вклад → большая система



идея



вход



проект



исслед.



данные



граф



модель



далее

S02

ПРОБЛЕМА НАЧИНАЮЩИХ

ML пугает

Сложно? Делим на роли!


эксперт

исследователь

кодер

координатор

не все делают одно и то же



идея



вход



проект



исслед.



данные



граф



модель



далее

S03

ПЕРВЫЙ ПОВОРОТ ИСТОРИИ

Искра

Сделаем открытый SciSpace!

open-source

свой сервис

GitHub?

ух ты!

идея стала продуктовой гипотезой

наш github репозиторий



идея



вход



проект



исслед.



данные



граф



модель



дальше

S04

НЕ РАСПИСАНИЕ, А АРТЕФАКТЫ

Курс = проект

Не слушаем. Собираем.

онлайн

офлайн

чат

репо

всё ведёт к одному результату

я сделал заготовку [репозитория курса](#). там сейчас практически везде заглушки, то есть со временем нужно будет убрать всё лишнее и добавить нужные нам данные и скрипты. я и все желающие будем этим заниматься на протяжении курса, чтобы получилась реально работающая библиотека. если вы выбрали роль заработчика, добавьте пожалуйста [в эту форму](#) гитхаб-аккаунт, чтобы я добавил гитхаб-аккаунты в репозиторий и выдал вам права, чтобы вам было проще вносить изменения в репозиторий



идея



вход



проект



исслед.



данные



граф



модель



дальше

S05 РОЛЬ ВАЖНЕЕ ИДЕАЛЬНОГО НАВЫКА

Добро пожаловать на курс!

Личный вклад — уже вклад

[статья](#)[коммит](#)[разметка](#)[помощь](#)

минимальный вклад снижает страх

то есть в проекте добавляется ещё одна роль - исследователь. если вы работаете на фронтире тематики курсового проекта - ии-агенты для науки, графы знаний, RAG и так далее - то можете поучаствовать.

Группа для разработчиков: обсуждаем гит-репозиторий, скрипты, библиотеки и другое

★ 16:58 ✓✓

Группа для экспертов: обсуждаем научную тематику - домены знания, статьи, схемы для заданий и другое

★ 16:57 ✓✓



идея



вход



проект



исслед.



данные



граф



модель



далее

S06

ВНЕШНЯЯ ЭКСПЕРТИЗА ПРОЕКТА

Поддержка сообщества

Люди поверили в нас

грант

облако

поддержка

план

проект должен быть полезным и развиваемым

Центр технологий для общества Yandex Cloud



идея



вход



проект



исслед.



данные



граф



модель



дальше

S07

НАУЧНОЕ ЯДРО ПРОЕКТА

Путь идеи

Статьи → граф → гипотезы

поиск

PDF

KG

RAG

из литературы рождается проверяемая идея



В рамках области информатика - ml, предлагаю в рамках золотого стандарта рассматривать конкурс ILSV RC в рамках 2012-2017 годов, то есть модели AlexNet, ZF Net, семейство VGG, GoogLeNet, ResNet и другие. Или как более глобальную тему можно выбрать алгоритм оптимизации Adam (вместе со следствиями, опровержениями и контропровержениями).



18:23

В рамках области информатика - ml, предлагаю в рамках... да, хорошая идея! тут получается можно выстроить сложные цепочки рассуждений, если есть опровержения

18:28 ✓

то есть до финального результата можно отследить как идея и методы развивались, это очень ценно

18:30 ✓



идея



вход



проект



исслед.



данные



граф



модель



дальше

S08

HUMAN-IN-THE-LOOP

Круговорот данных

ДЗ стало топливом модели

trajectory

review

feedback

SFT

учебные задания превращаются в обучающий сигнал

мы их потом все зальем на хаггингфейс и уже оттуда можно будет подгружать

22:04 ✓✓



идея



вход



проект



исслед.



данные



граф



модель



дальше

S09

ЗАДАНИЕ 1

Траектория рассуждений

Как родилась научная идея?

cutoff

evidence

inference

next question

не пересказ, а путь рассуждения

блокнот: задание 1



идея



вход



проект



исслед.



данные



граф



модель



дальше

S10

UX ТОЖЕ ML-КАЧЕСТВО

Баг → патч

Форма сломалась? Чиним!

сохраняем

offline

клик

YAML

обратная связь стала улучшением

И еще одно (крайне для меня неприятное открытие). Заполнила форму, нажала на кнопку проверить и сохранить. Из-за того, из-за одной маленькой ошибки выдал вердикт с ошибкой. При этом все ранее заполненные поля не сохранились. Видимо придется начинать сначала :(

17:56



идея



вход



проект



исслед.



данные



граф



модель



дальше

S11

ЗАДАНИЕ 2

Граф-лес

1179 рёбер? Нужен фильтр!

аccept

reject

why?

смысл

не всё корректное полезно

блокнот: задание 2



идея



вход



проект



исслед.



данные



граф



модель



дальше

S12

ИНЖЕНЕРНЫЙ СЛОЙ

Под капотом

Инструмент собирается из деталей

PyMuPDF

Neo4j

Qdrant

MCP

ML-продукт — это стек, а не одна модель

я завёл несколько тестовых issues, посмотрите пожалуйста, понятны ли задачи?

18:37 ✓✓



идея



вход



проект



исслед.



данные



граф



модель



далее

S13

ПУБЛИЧНЫЙ АРТЕФАКТ

Датасет

Домашка вышла в мир

Hugging Face

exports

images

GPL-3.0

результат живёт после занятия

наш датасет на Hugging Face



идея



вход



проект



исслед.



данные



граф



модель



дальше

S14 ИССЛЕДОВАТЕЛЬСКАЯ АМБИЦИЯ

Картинки + время

Модель смотрит, когда и где

рисунки

таблицы

страницы

temporal KG

научная статья — не только текст

Тут учитывая особенности научных текстов, нужно внимательно присмотреться к возможностям этих библиотек. Т.к много графики, мат формул и таблиц

14:28



идея



вход



проект



исслед.



данные



граф



модель



дальше

S15

ЗАДАНИЕ 3

Честная проверка

Не верим — сравниваем!

blind A/B

baseline

fine-tuned

оценка

качество надо измерять, а не угадывать

блокнот: задание 3



идея



вход



проект



исслед.



данные



граф



модель



дальше

S16

МЕТОДИКА ТОЖЕ АРТЕФАКТ

Открытый курс

Методика тоже open-source

Git

CI

ревью

облако

курс можно изучать и улучшать

наш открытый курс на SourceCraft



идея



вход



проект



исслед.



данные



граф



модель



дальше

S17 для самых неподготовленных

Почему работает

Новичку нужен безопасный шаг

шаблон

роль

пример

feedback

сложность не убираем — масштабируем

100 связей в ручном режиме что-то тоже такое себе...) 19:56

Так в сто раз меньше - это 11-12. Самое то :) 19:58

Не много, но честная работа 19:58



идея



вход



проект



исслед.



данные



граф



модель



дальше

S18

ГЛАВНЫЙ РЕЗУЛЬТАТ

Продолжение следует

Курс стал командой

артефакты живут

люди растут

модель учится

open-source курс — это про участие

наш чат в TG



идея



вход



проект



исслед.



данные



граф



модель



дальше

Data Fest 2026

Спасибо!

TELEGRAM

@visualcomments

EMAIL

aa.kostin@phystech.edu

SLIDES

https://github.com/top-papers/top-papers-graph/tree/main/conferences/datafest_2026

